

Projet 5A

Prédiction de score

Remerciements

Nous adressons nos sincères remerciements à Madame Leger, notre responsable de projet, pour son encadrement et ses conseils avisés. Son soutien nous a permis de structurer notre travail efficacement et d'aboutir à des résultats pertinents.

Résumé

L'intelligence artificielle peut-elle battre les bookmakers sur leur propre terrain ? Pour répondre à cette question, nous avons bâti une chaîne de modélisation intégrale. Nous avons d'abord résolu la complexité des données hétérogènes grâce au Fuzzy Matching, avant de garantir l'intégrité de nos prédictions par un découpage temporel strict, éliminant tout risque de biais d'anticipation. Une fois ces défis techniques relevés, nos algorithmes (Régression Logistique, Random Forest et XGBoost) ont été confrontés à la réalité du marché sur plus de 52 000 matchs. Si le seuil de rentabilité n'a pas été franchi (ROI de -5,79%), le modèle XGBoost a réalisé une bonne performance : s'aligner sur la précision des experts du marché. Ce projet démontre que si un pipeline de données complet permet d'égaler les bookmakers, les battre nécessite une information que l'historique statistique seul n'a pas.

Mots-clés

- Data Science
- Football
- Paris Sportifs
- Modélisation Prédictive
- Efficience des Marchés (EMH)
- Feature Engineering

Abstract

Can Artificial Intelligence beat bookmakers at their own game? To answer this question, we built a comprehensive modeling pipeline. We first addressed the complexity of heterogeneous data using Fuzzy Matching, before ensuring the integrity of our predictions through a strict time-series validation protocol, effectively eliminating any risk of look-ahead bias. Once these technical challenges were met, our algorithms (Logistic Regression, Random Forest, and XGBoost) were tested against market reality on over 52,000 matches. While the break-even point was not reached (ROI of -5.79%), the XGBoost model achieved a strong performance: matching the precision of market experts. This project demonstrates that while a rigorous data pipeline allows for equaling bookmakers, beating them requires information that historical statistics alone do not possess.

Keywords

- Data Science
- Football Analytics
- Sports Betting
- Predictive Modeling
- Efficient Market Hypothesis (EMH)
- Feature Engineering

Table de matière

Table de matière.....	4
1. Liste des figures	7
2. Liste des abréviations	8
3. Introduction.....	9
4. Données et Ingénierie des Fonctionnalités	11
4.1 Acquisition et Fusion des Sources Hétérogènes	11
4.1.1 Stratégie de Réconciliation des Entités	11
4.1.2 Quantification du Gain Informationnel	12
4.2 Audit de Qualité et Sélection du Périmètre (<i>Data Profiling</i>).....	12
4.2.1 Comparaison des Stratégies : L'Entonnoir de Sélection.....	12
4.2.2 Justification Quantitative de la Coupure Temporelle (2006).....	13
4.3 <i>Feature Engineering</i> : Construction de la Dynamique Temporelle	14
4.3.1 Lissage par Fenêtres Glissantes (Rolling Windows).....	14
4.3.2 Espace des Variables Générées (X_train)	14
5. Analyse Exploratoire des Données (EDA)	16
5.1 Distribution de la Target et Biais Structurel (Avantage Domicile)	16
5.2 Structure du Signal et Analyse des Corrélations	17
5.3 Analyse de Stationnarité et Risque de Dérive	19
6. Protocole Expérimental et Cadre de Validation	21
6.1 Stratégie de Validation : Validation Croisée Temporelle	21
6.1.1 Protocole de Validation	21
6.1.2 Justification Scientifique.....	21
6.2 Métriques d'Évaluation Multidimensionnelles	22
6.2.1 Discrimination : La Performance Brute (Accuracy)	22
6.2.2 Calibration : La Qualité de la Confiance (Log Loss & Brier Score)	22
6.2.3 Métrique Métier : La Réalité Économique (ROI)	23
6.3 Stratégie de Pondération : Le Dilemme du Match Nul.....	23
6.3.1 Comparaison des Stratégies : Balanced vs Custom.....	23
6.3.2 Le Ratio Signal/Bruit	24
7. Modélisation Prédictive et Analyse Comparative	25

7.1 Baseline : La Régression Logistique (RL)	25
7.1.1 Présentation de la Méthode.....	25
7.1.2 Validation du Benchmark : Le Test de Contrôle (V1)	25
7.1.3 Performance du Modèle Aveugle (V2)	25
7.1.4 Analyse Comportementale : Le Biais de la Classe Majoritaire	26
7.2 Challenger : Random Forest (RF)	27
7.2.1 Présentation de la Méthode : Réduction de la Variance	27
7.2.2 Validation du Benchmark (V1).....	28
7.2.3 Performance du Modèle Aveugle (V2)	28
7.2.4 Analyse Comportementale	29
7.3 Le Gradient Boosting (XGBoost)	29
7.3.1 Présentation de la Méthode : Correction Séquentielle.....	29
7.3.2 Paramétrage et Stratégie de Régularisation.....	30
7.3.3 Validation du Benchmark : Le Test de Contrôle (V1)	30
7.3.4 Performance du Modèle Aveugle (V2)	31
7.3.5 Analyse Structurale	31
7.3.6 Calibration et Fiabilité (ECE)	32
7.3.7 Décryptage de la Boîte Noire	32
7.3.8 Diagnostic Limite : L'Asymptote d'Information	34
8. Discussion Critique et Analyse Financière	35
8.1 Cadre d'Analyse et Rentabilité Comparée.....	35
8.1.1 Définitions des Métriques Financières.....	35
8.1.2 Analyse de Rentabilité (ROI) des 3 Modèles	35
8.1.3 La Neutralité face à l'Efficiencia (EMH)	36
8.2 Profilage de la Performance et Zones de "Value"	37
8.2.1 La Dichotomie Favori / Outsider.....	37
8.2.2 Mise en Garde Épistémologique	38
8.3 Analyse Comparative face au Consensus de Marché	38
8.3.1 Définition du Benchmark (V0) et Performance Relative	38
8.3.2 La Règle du 95/5	38
9. Discussion : Limites et Obstacles Rencontrés.....	40

10. Conclusion Générale et Perspectives	41
11. Apport Personnel et Retour d'Expérience.....	42
12. Bibliographie.....	43
13. Annexe	44
13.1 Dictionnaire des Variables	44
13.2 Paramètres des Modèles (Reproductibilité).....	46
13.3 Exemple de Réconciliation (Fuzzy Matching)	47
13.4 Tableaux de Résultats Financiers (extrait notebook modélisation XGBoost).....	48
13.5 La Visualisation de l'Arbre XGBoost (Tree Plot)	49
13.6 Visualisation SHAP importance pour respectivement RL et RF avec l'influence (cas du modèle aveugle).....	50
13.7 Courbe d'apprentissage pour RL	51

1. Liste des figures

Figure 1 : Évolution du taux de complétude des variables	13
Figure 2 : Distribution des résultats finaux.....	16
Figure 3 : Matrice de corrélation entre victoire à domicile et variables principales	18
Figure 4 : Évolution temporelle de la moyenne de buts par match	19
Figure 5 : Importance des variables dans la Régression Logistique	26
Figure 6 : Matrice de confusion de la Régression Logistique	27
Figure 7 : Importance des variables (Random Forest)	28
Figure 8 : Matrice de confusion du modèle Random Forest.....	29
Figure 9 : Matrice de confusion du XGBoost.....	31
Figure 10 : Courbe de calibration du XGBoost	32
Figure 11 : Importance globale des variables du XGBoost (SHAP Values)	33
Figure 12 : Courbes d'apprentissage du XGBoost	34
Figure 13 : Évolution du profit cumulé (en unités).....	36
Figure 14 : Rentabilité par tranche de cote.....	37

2. Liste des abréviations

Abréviation	Définition Complète	Contexte
ECE	Expected Calibration Error	Mesure de l'écart moyen entre la probabilité prédite par le modèle et la fréquence réelle de l'événement.
Elo	Classement Elo	Système d'évaluation du niveau relatif des équipes.
EMH	Efficient Market Hypothesis	Théorie financière selon laquelle les prix (ici les cotes) reflètent toute l'information disponible.
H / D / A	Home / Draw / Away	Nomenclature standard pour les résultats : Victoire Domicile, Match Nul, Victoire Extérieur.
ML	Machine Learning	Apprentissage Automatique.
RF	Random Forest	Forêts Aléatoires (algorithme d'apprentissage ensembliste).
RL	Régression Logistique	Modèle statistique linéaire utilisé pour la classification binaire ou multi-classes.
ROI	Return On Investment	Retour sur Investissement (Profit Net / Mise Totale).
TSS	Time Series Split	Méthode de validation croisée respectant la chronologie temporelle (pas de mélange futur/passé).
XGB	XGBoost	eXtreme Gradient Boosting (algorithme de boosting de gradient optimisé).
xG	Expected Goals	Métrique probabiliste mesurant la qualité d'une occasion de but.

3. Introduction

Le football est un sport complexe où l'aléa joue un rôle important. Si la prédiction des résultats a longtemps relevé de l'intuition, les travaux fondateurs de Dixon & Coles [2] ont ouvert la voie à une certaine approche statistique, mettant en évidence dès 1997 certaines inefficacités structurelles des marchés de paris. Dans ce marché globalisé, les cotes fixées par les bookmakers ne sont pas de simples probabilités arbitraires : elles matérialisent un consensus de marché, combinant une quantité massive d'informations historiques et contextuelles. Selon l'Hypothèse d'Efficiéce des Marchés (EMH), battre ce consensus de manière systématique sur le long terme relève de l'anomalie statistique, tant les prix (les cotes) sont censés intégrer instantanément toute l'information disponible.

C'est dans ce cadre théorique exigeant que s'inscrit cette étude. La problématique centrale de ce projet est d'évaluer la capacité prédictive intrinsèque des données publiques. Une modélisation rigoureuse, fondée exclusivement sur des données endogènes (historique des scores, classements Elo, statistiques techniques), permet-elle de capturer la hiérarchie sportive avec suffisamment de fidélité pour rivaliser avec les modèles propriétaires des bookmakers ? En d'autres termes : est-il possible de générer un avantage compétitif et une rentabilité économique en exploitant uniquement le "passé mathématique" des équipes, sans intégrer de données exogènes (blessures, météo, contexte psychologique) ?

Pour répondre à cette question, nous avons déployé une démarche scientifique structurée autour de la donnée. Notre approche repose sur la construction d'un pipeline de traitement complet, intégrant la réconciliation de sources hétérogènes et une ingénierie de fonctionnalités avancée. Afin d'éprouver nos hypothèses, nous avons mis en compétition trois architectures d'apprentissage supervisé, représentatives d'une complexité croissante :

1. Régression Logistique : Pour tester la linéarité du signal.
2. Random Forest : Pour évaluer l'apport du Bagging et la gestion de la variance.
3. XGBoost : Pour exploiter le Gradient Boosting et optimiser le biais.

L'ensemble de ces travaux a été mené sous une contrainte stricte de Validation Temporelle (Time Series Split) afin de proscrire tout biais d'anticipation et garantir la reproductibilité des résultats en conditions de production.

Ce rapport s'articule autour de cinq axes majeurs :

La 1^{ère} partie détaille le processus de Data Engineering, de la fusion complexe des sources à la construction de l'espace des variables.

La 2^{ème} partie présente l'Analyse Exploratoire (EDA), identifiant les invariants statistiques (Avantage Domicile) et les biais structurels du football.

La 3^{ème} partie définit le protocole expérimental et justifie notre stratégie unifiée de gestion de la classe minoritaire ("Match Nul").

La 4^{ème} partie expose les performances techniques comparées de nos modèles (Accuracy, Calibration, SHAP Values).

La 5^{ème} partie, enfin, propose une discussion critique sur la rentabilité financière (ROI) et l'efficience du marché, avant de conclure sur les limites informationnelles rencontrées.

4. Données et Ingénierie des Fonctionnalités

La performance d'un modèle d'apprentissage supervisé étant intrinsèquement bornée par la qualité des données qui l'alimentent ("Garbage In, Garbage Out"), la première phase de ce projet a consisté à construire un bon pipeline de données. Cette étape vise à transformer des données brutes disparates en un jeu de données cohérent et riche en signal prédictif, capable de capturer la dynamique temporelle du football sur la période 2000-2025.

4.1 Acquisition et Fusion des Sources Hétérogènes

Pour modéliser efficacement l'issue d'un match, notre approche repose sur l'hybridation de deux typologies d'informations complémentaires : les statistiques de match et le niveau intrinsèque des équipes. À cette fin, nous avons fusionné deux sources de données de référence.

Premièrement, il y a des données événementielles et de marché (Source : Football-Data.co.uk) : cette base constitue notre "Vérité Terrain". Elle fournit le vecteur cible (FTResult), les statistiques techniques détaillées (Tirs, Corners, Fautes) ainsi que les cotes d'ouverture agrégées des principaux bookmakers. Elle capture la dimension immédiate et volatile de la performance.

Enfin, il y a des données de Classement Elo (Source : ClubElo.com) : contrairement au classement officiel par points, sujet à une remise à zéro saisonnière, le système Elo offre une mesure de la force latente d'une équipe. En intégrant l'historique influencé par la qualité de l'adversaire, il capture l'inertie et la hiérarchie structurelle du football européen, indispensable pour prédire les rapports de force.

4.1.1 Stratégie de Réconciliation des Entités

L'un des défis techniques majeurs de ce projet a résidé dans l'absence d'identifiant unique commun entre les deux bases de données. Cette disparité se manifeste par des variations dans la dénomination des clubs, telles que « Man Utd » face à « Manchester United ». Une simple jointure stricte sur les chaînes de caractères aurait engendré un taux de rejet estimé à plus de 40 %. Une telle perte de données aurait introduit un biais de sélection important, en excluant systématiquement les clubs aux dénominations complexes, qui sont souvent des outsiders.

Afin de surmonter ce problème d'appariement et de garantir l'intégrité du jeu de données, nous avons mis en œuvre un algorithme de Fuzzy Matching. Ce protocole repose sur trois étapes clés :

Premièrement, nous avons calculé la similarité entre les entités en utilisant la distance de Levenshtein (via la librairie FuzzyWuzzy), ce qui permet de quantifier la proximité orthographique entre les noms de clubs.

Ensuite, nous avons appliqué un seuillage automatique pour valider les paires présentant un score de similarité supérieur à 85 %, assurant ainsi une première correspondance fiable.

Enfin, une correction humaine a été nécessaire pour traiter les cas ambigus ou les changements de noms historiques non détectés par l'algorithme. Cette étape a abouti à la création d'un dictionnaire de mappage manuel (club_mapping_clean.csv).

4.1.2 Quantification du Gain Informationnel

Cette méthodologie rigoureuse a permis de maximiser la conservation de l'information. L'analyse de complétude sur le dataset global démontre l'efficacité du processus :

- Complétude Elo (Approche Naïve) : < 60%.
- Complétude Elo (Après Fuzzy Matching) : 90.63%.

Ce processus nous a permis d'enrichir le jeu de données avec des variables structurelles fortes (EloDiff, EloAdvantage), garantissant une couverture de 100% sur le périmètre final de l'étude qui concerne les équipes des championnats retenus à la fin, éliminant ainsi tout besoin de suppression sur ces prédicteurs essentiels.

4.2 Audit de Qualité et Sélection du Périmètre (*Data Profiling*)

L'agrégation initiale des sources a produit un jeu de données brut massif (Matches_with_Elo) comportant 228 377 observations réparties sur 42 championnats. Cependant, le volume ne saurait prévaloir sur la densité informationnelle. Une phase d'audit systématique (Data Profiling) a révélé des lacunes sur la structure du jeu de données global.

L'analyse des valeurs manquantes sur l'ensemble du corpus met en évidence une inexploitable des variables techniques clés pour une modélisation fine :

- Stats de Tirs (Home/Away Shots) : 50.7% de valeurs manquantes.
- Stats de Corners (Home/Away Corners) : 50.9% de valeurs manquantes.
- Horaire du match (MatchTime) : 57.6% de valeurs manquantes.

Face à ce constat, avec plus d'un match sur deux inexploitable pour le Feature Engineering avancé, nous avons opéré une sélection pour garantir la stabilité des modèles.

4.2.1 Comparaison des Stratégies : L'Entonnoir de Sélection

Dans une démarche de rationalisation du périmètre d'étude, nous avons comparé trois stratégies de constitution du dataset en évaluant le compromis entre le volume de données et leur densité informationnelle (taux de complétude des variables explicatives) :

Tout d'abord il y a l'approche Globaliste (Matches_All, 2000-2025). Bien que cette stratégie offre le volume le plus important (165 619 matchs), elle présente une complétude moyenne

insuffisante de 82,0%. Nous avons écarté cette option car l'inclusion des ligues mineures et des saisons les plus anciennes introduit un bruit statistique excessif. Conserver ce périmètre aurait contraint à retirer près de la moitié des statistiques de jeu, générant un biais structurel incohérent pour la modélisation.

Ensuite il y a eu l'approche récente (Matches_Recent, 2006-2025). Avec 138 312 matchs et une complétude de 92,0%, cette option intermédiaire présente une qualité substantielle. Toutefois, elle a également été rejetée car la profondeur historique ou la disparité des championnats ne permettaient pas de capturer fidèlement les cycles longs de performance (inertie du Elo) à travers différentes ères tactiques.

Enfin, on a terminé avec une approche de sélection de championnat (Matches_Select_Championnats, 2006-2025) : Notre choix s'est finalement porté sur ce périmètre restreint. Bien que le volume final soit réduit à 52 580 matchs (soit une division par 5 du volume initial), cette sélection garantit une complétude optimale de 97,3 %. Ce compromis privilégie la qualité à la quantité : nous nous assurons ainsi que la quasi-totalité des observations restantes dispose d'un signal complet et exploitable.

4.2.2 Justification Quantitative de la Coupure Temporelle (2006)

Le choix d'exclure les saisons antérieures à 2006/2007 découle directement de l'analyse des taux de valeurs manquantes par saison.




Figure 1 : Évolution du taux de complétude des variables

Comme l'illustre la Figure 1, la saison 2006 marque un point d'inflexion dans la collecte de données sportives. Avant cette date, la granularité des statistiques est trop aléatoire pour alimenter des algorithmes de Gradient Boosting. En sélectionnant la fenêtre 2006-2025, nous stabilisons quasi constamment la complétude au-dessus de 80%.

4.3 Feature Engineering : Construction de la Dynamique Temporelle

Le passage des données brutes aux variables prédictives constitue le cœur de la démarche de modélisation. Une observation isolée (ex: "3 tirs cadrés lors du match J-1") porte une information anecdotique, soumise à l'aléa du jeu.

L'objectif du Feature Engineering a été de transformer ces séries temporelles en une représentation vectorielle de l'état de forme de chaque équipe à l'instant t , en respectant strictement le principe de causalité (utilisation exclusive des informations disponibles à $t-1$).

4.3.1 Lissage par Fenêtres Glissantes (Rolling Windows)

Le football est un sport à faible score et haute variance aléatoire. Se baser uniquement sur la performance du dernier match introduirait un bruit considérable. Pour extraire un signal tendanciel, nous avons appliqué une transformation par moyenne mobile simple sur une fenêtre glissante de profondeur $k=5$.

Pour une variable brute X (ex: Tirs Cadrés), la variable prédictive X_{smooth} à l'instant t pour une équipe est définie par :

$$X_{smooth}^{(t)} = \frac{1}{k} \sum_{i=1}^k X^{(t-i)}$$

Le choix du paramètre $k=5$ (les 5 derniers matchs) constitue un compromis optimal entre réactivité et stabilité :

- $k > 10$ (Trop d'inertie) : Le modèle dilue l'information récente et échoue à détecter les changements d'état soudains (blessures, déclic psychologique).
- $k < 3$ (Trop de variance) : Sensibilité excessive au bruit d'un match aberrant (Outlier).

4.3.2 Espace des Variables Générées (X_{train})

La matrice de fonctionnalités finale, constituée de 30 variables explicatives, a été structurée selon une hiérarchie de l'information articulée autour de trois axes descriptifs complémentaires :

Le premier axe vise à capturer le niveau intrinsèque des équipes et la hiérarchie de force établie sur le long terme. Cette approche repose principalement sur le classement Elo, dont la supériorité prédictive sur les modèles purement statistiques a été établie dans la littérature par Hvattum & Arntzen [1]. Concrètement, le modèle s'appuie sur la variable maîtresse EloDiff (le différentiel de points Elo entre les deux opposants), complétée par l'indicateur binaire EloAdvantage et par la dynamique comptable récente (Form_Last5), mesurant les points engrangés sur les cinq dernières rencontres.

Le second axe se concentre sur la qualification de la performance, ou la manière, indépendamment du résultat comptable. Lissées sur une fenêtre glissante de cinq matchs, ces variables permettent de quantifier trois dimensions du jeu : le volume offensif (via la moyenne des tirs tentés HomeShots et cadrés HomeTarget), la pression territoriale (via le nombre de corners obtenus) et enfin l'intensité physique couplée à la discipline tactique (via le différentiel de cartons CardsDiff). Ces métriques enrichissent le modèle en lui fournissant des indicateurs de la qualité de jeu réelle.

Enfin, la construction des variables intègre une distinction fondamentale liée au biais structurel de l'avantage du terrain (qui représente historiquement environ 45 % des victoires). Afin d'éviter qu'une agrégation globale ne masque les disparités de performance, nous avons disjoint l'ensemble des indicateurs : la force à domicile d'une équipe est calculée indépendamment de sa force à l'extérieur. Ce changement est crucial pour permettre aux algorithmes d'identifier les profils d'équipes asymétriques, souvent intraitables dans leur stade mais vulnérables en déplacement.

5. Analyse Exploratoire des Données (EDA)

Avant toute démarche de modélisation prédictive, une phase d'audit des données est indispensable pour qualifier la structure du signal, vérifier l'intégrité du dataset et identifier les biais potentiels. Notre démarche s'est appuyée sur une méthodologie hybride, combinant puissance de calcul et expertise métier :

Nous avons commencé par un audit technique automatisé via YData Profiling. Nous avons généré des rapports de profilage automatique sur le dataset final. Cette étape a validé la qualité intrinsèque des variables : détection d'asymétrie, vérification de l'absence de valeurs nulles sur les features critiques et analyse des corrélations de Pearson. Le rapport confirme la haute qualité du jeu de données Matches_Select_Championnats (taux de complétude > 97% sur les variables techniques).

Puis il y a eu l'analyse métier manuelle. En complément, une exploration ciblée a été menée pour interroger les invariants statistiques spécifiques au football : la réalité de l'avantage du terrain, la distribution atypique des cotes et la puissance prédictive du Elo.

Cette double analyse conditionne les choix méthodologiques de la Partie III, dictant notamment le choix des métriques d'évaluation face au déséquilibre des classes.

5.1 Distribution de la Target et Biais Structurel (Avantage Domicile)

L'analyse univariée de la variable cible FTResult (Full Time Result) met en évidence une caractéristique fondamentale du football professionnel : l'Avantage du Terrain.

Value	Count	Frequency (%)
H	23565	44.8%
A	15393	29.3%
D	13622	25.9%

Figure 2 : Distribution des résultats finaux

Comme l'illustre la Figure 2, la distribution des classes n'est pas uniforme. Sur notre périmètre d'étude, elle suit une répartition structurellement déséquilibrée :

- Victoire à Domicile (Home) : 44.8 %
- Victoire à l'Extérieur (Away) : 29.3 %
- Match Nul (Draw) : 25.9 %

Ce déséquilibre n'est pas un lié à l'échantillonnage, mais a une réalité systémique documentée (pression du public, familiarité avec l'aire de jeu). Ce constat impose deux contraintes majeures à notre stratégie de modélisation :

Tout d'abord il y a la redéfinition de la baseline (Le seuil de 45%). L'Accuracy ne peut être interprétée de manière absolue (le hasard n'est pas à 33%). Un modèle naïf qui prédirait systématiquement la victoire à domicile obtiendrait mécaniquement une précision de 44.8%. Pour être considéré comme utile, tout modèle prédictif devra démontrer une performance significativement supérieure à ce seuil plancher.

Enfin il y a le défi de la classe minoritaire (Le Nul). Avec seulement un quart des occurrences, le match nul est statistiquement défavorisé. Dans un apprentissage supervisé standard, un algorithme cherchant à minimiser l'erreur globale aura une tendance naturelle à sous-prédire cette classe pour se concentrer sur les classes majoritaires. Cela justifie par anticipation la nécessité d'une stratégie de pondération et l'utilisation de métriques probabilistes fines.

5.2 Structure du Signal et Analyse des Corrélations

Afin de qualifier la puissance prédictive de nos variables et d'identifier les redondances potentielles, nous avons procédé à une double analyse : distributionnelle (univariée) et relationnelle (bivariée).

Avant même d'analyser les corrélations, l'étude de la distribution des cotes (OddHome) révèle une structure particulière du signal. Avec un coefficient d'asymétrie (Skewness) de 4.89, la distribution est fortement étalée vers la droite.

Alors que la médiane se situe à 2.13, la présence de valeurs extrêmes, c'est-à-dire les cotes > 20.0, indique que le marché gère des événements avec de très faible probabilité. Cette non-normalité justifie techniquement le rejet des modèles linéaires simples au profit d'approches non-paramétriques.

Le calcul de la matrice de corrélation de Pearson permet d'établir une hiérarchie nette des déterminants de la performance.




Figure 3 : Matrice de corrélation entre victoire à domicile et variables principales

L'analyse de la Figure 3 confirme que le football est, à l'échelle macroscopique, un système régi par la hiérarchie des forces.

Nous observons une corrélation massive de +0.889 entre la différence de Elo (EloDiff) et la probabilité implicite de victoire à domicile (PHome_norm).

L'écart de niveau intrinsèque capture près de 89% de la variance explicable des cotes. Le Elo n'est pas juste un indicateur mais bien le pilier ici.

En comparaison, les variables techniques issues de l'ingénierie des fonctionnalités (Moyennes glissantes des Tirs, Corners sur 5 matchs) affichent des corrélations modestes avec la cible (généralement $|r| < 0.15$).

Prises isolément, ces variables sont bruiteuses. Elles n'agissent pas comme des prédicteurs primaires mais comme des variables d'ajustement, susceptibles d'apporter de la nuance là où le Elo ne voit que la force brute.

De plus, l'analyse croisée révèle un point critique pour la modélisation : la colinéarité quasi-parfaite (r proche de 0.90) entre nos meilleures variables prédictives (EloDiff) et la cible du marché (Odds).

Cette observation a deux conséquences majeures :

Elle démontre mathématiquement que les bookmakers intègrent déjà la logique du classement Elo dans leurs algorithmes. Nos modèles ne pourront pas générer de profit simplement en apprenant le Elo car cette information est déjà pricée.

Enfin, une telle corrélation rendrait les coefficients d'une Régression Logistique instables. Cela valide le choix des méthodes d'ensembles (Random Forest, XGBoost), naturellement résistants à la multicollinéarité et capables de gérer la redondance entre les variables techniques.

5.3 Analyse de Stationnarité et Risque de Dérive

La profondeur historique de notre fenêtre d'étude (19 saisons, 2006-2025) soulève une question fondamentale de modélisation : le processus générateur de données est-il stationnaire ?

En d'autres termes, les lois statistiques du football ont-elles évolué significativement (évolution tactique, introduction de la VAR, arbitrage) au point de rendre les données anciennes obsolètes ? Un changement conceptuelle majeure invaliderait notre approche d'apprentissage global.

Pour vérifier cette hypothèse, nous avons analysé l'évolution temporelle des métriques fondamentales du jeu.




Figure 4 : Évolution temporelle de la moyenne de buts par match

L'analyse des séries temporelles, illustrée par la Figure 4, confirme une stabilité suffisante pour la modélisation :

La moyenne de buts par match oscille dans une bande étroite autour de 2.7 buts, avec une tendance à la hausse mais pas suffisante pour remettre en cause l'étude.

Egalement, bien que l'avantage du terrain connaisse de légères fluctuations, la proportion de victoires à domicile reste globalement stationnaire autour de son point d'équilibre de 45%.

Cette constance des distributions valide la légitimité d'entraîner nos modèles sur l'intégralité de la période 2006-2025.

Bien que le football ait évolué tactiquement, ses invariants statistiques présentent une cohérence suffisante pour considérer les matchs de 2010 et ceux de 2024 comme étant issus de la même distribution.

Cette validation nous permet de maximiser la taille de l'échantillon d'entraînement.

6. Protocole Expérimental et Cadre de Validation

Cette partie définit le cadre méthodologique strict et les outils de vérification que nous avons imposés à l'ensemble de nos architectures (Régression Logistique, Random Forest, XGBoost) présentées dans la 4^{ème} partie. L'objectif est de garantir que les performances mesurées reflètent une capacité réelle de généralisation.

6.1 Stratégie de Validation : Validation Croisée Temporelle

Dans la majorité des problèmes d'apprentissage supervisé, la validation croisée avec mélange aléatoire constitue la norme. Cependant, cette approche est proscrite dans notre étude.

Mélanger aléatoirement les matchs de 2006 et 2024 pour constituer les jeux d'entraînement et de test introduirait une fuite de données massive. Un modèle ne peut avoir accès, même indirectement, aux tendances tactiques ou statistiques de 2024 pour prédire un match de 2006.

6.1.1 Protocole de Validation

Pour respecter scrupuleusement la chronologie, nous avons mis en œuvre une stratégie de Validation Croisée Temporelle Expansive, implémentée via la méthode `TimeSeriesSplit` de la librairie Scikit-Learn.

Le protocole divise l'axe temporel en 5 itérations (Folds) séquentielles :

- Fold 1 : Entraînement sur [2006-2013] → Test sur [2013-2016]
- Fold 2 : Entraînement sur [2006-2016] → Test sur [2016-2019]
- Fold 3 : Entraînement sur [2006-2019] → Test sur [2019-2022]
- Fold 4 : Entraînement sur [2006-2022] → Test sur [2022-2025]
- Fold 5 : Entraînement sur [2006-2024] → Test sur la fin de l'échantillon.

6.1.2 Justification Scientifique

Cette architecture de validation, appliquée uniformément à tous les modèles de la partie suivante, présente deux points forts pour la rigueur de nos conclusions :

Tout d'abord, à chaque itération i , le modèle ne voit strictement que les données antérieures à l'instant t du test. Il est impossible pour l'algorithme d'utiliser une information future pour corriger une erreur passée.

De plus, ce découpage reproduit fidèlement la situation réelle d'un analyste ou d'un parieur. Dans un contexte opérationnel, le modèle est ré-entraîné périodiquement avec tout l'historique disponible pour prédire les événements futurs. C'est la seule métrique honnête pour évaluer la viabilité économique d'une stratégie sur le long terme.

C'est donc sur la moyenne de ces 5 plis que seront jugés et comparés nos modèles dans la section suivante.

6.2 Métriques d'Évaluation Multidimensionnelles

Dans un problème de classification standard, le taux de bonnes prédictions (Accuracy) est souvent la métrique importante. Toutefois, dans le contexte des paris sportifs, caractérisé par des classes déséquilibrées, cette mesure est insuffisante, voire trompeuse. Un modèle peut afficher une excellente précision en pariant systématiquement sur les ultra-favoris (cotes < 1.10), tout en générant des pertes massives dès qu'une surprise survient.

Pour capturer la complexité du problème, nous avons adopté une stratégie d'évaluation triangulaire, où l'on analyse la performance sous trois angles : la discrimination, la calibration probabiliste et la rentabilité économique.

6.2.1 Discrimination : La Performance Brute (Accuracy)

Bien que limitée, l'Accuracy reste notre indicateur de référence pour situer la capacité globale du modèle à identifier le vainqueur face au hasard (33%) et à la stratégie naïve (Dummy Classifier d'environ 45%).

Elle est définie par le rapport des prédictions correctes sur le nombre total d'échantillons N :

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(\hat{y}_i = y_i)$$

Où $\hat{y}_i$ est la classe prédite et y_i la classe réelle. C'est une mesure de tendance utile pour la comparaison inter-modèles, mais elle ignore la confiance associée à la prédiction.

6.2.2 Calibration : La Qualité de la Confiance (Log Loss & Brier Score)

Le cœur de notre approche reposant sur la détection de Value (écart entre notre probabilité estimée et la probabilité implicite du bookmaker), la calibration du modèle est critique. Un modèle qui prédit une victoire à 80% doit avoir raison 80% du temps.

- Logarithmic Loss (Log Loss) :

Tout d'abord il y a notre fonction de coût principale : la Logarithmic Loss. Contrairement à l'Accuracy qui est binaire, la Log Loss évalue l'incertitude du modèle en pénalisant de manière exponentielle une confiance mal placée.

Pour un problème multi-classes ($M=3$), elle se formule ainsi :

$$\text{Log Loss} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^M y_{i,j} \log(p_{i,j})$$

Où $y_{\{i,j\}}$ est l'indicateur binaire (0 ou 1) si la classe j est la bonne pour l'observation i , et $p_{\{i,j\}}$ la probabilité prédite. Cette métrique nous force à construire des modèles "honnêtes" sur leurs propres doutes.

Le Brier Score est utilisé en complément. C'est une règle de score propre qui mesure la distance quadratique moyenne entre les probabilités prédites et le résultat réel. Il quantifie la fiabilité (Reliability) :

$$BS = \frac{1}{N} \sum_{i=1}^N (p_i - o_i)^2$$

6.2.3 Métrique Métier : La Réalité Économique (ROI)

Enfin, le juge de paix est la capacité du modèle à battre la marge du bookmaker. Nous calculons le Retour sur Investissement pour une stratégie de mise unitaire :

$$ROI(\%) = \left(\frac{\text{Gain Total} - \text{Mise Totale}}{\text{Mise Totale}} \right) \times 100$$

Nous évaluons ce ROI globalement, mais aussi par tranches de confiance. Cela nous permet de vérifier si une sélectivité telle que « ne parier que si la confiance > 60% » améliore la rentabilité ou si elle ne fait qu'augmenter la variance.

Cette triade (Classement / Calibration / Rentabilité) permet de détecter les modèles sûrs d'eux mais faux, qui est un piège classique de certaines méthodes lorsqu'elles ne sont pas recalibrées.

6.3 Stratégie de Pondération : Le Dilemme du Match Nul

Le déséquilibre naturel des classes identifié en phase exploratoire (seulement 24% de matchs nuls) pose un défi classique en apprentissage supervisé : celui de la classe minoritaire.

Cependant, la spécificité du football réside dans la nature du match nul. Il ne s'agit pas seulement d'un événement rare, mais d'un événement bruité. Dans un sport à faible score, un match nul peut résulter d'un équilibre parfait des forces ou d'une maladresse aléatoire d'un attaquant. Distinguer ces deux causes est difficile pour un modèle statistique.

6.3.1 Comparaison des Stratégies : Balanced vs Custom

Afin d'arbitrer le compromis délicat entre la capacité de détection (Rappel) et la précision des prédictions, nous avons évalué comparativement deux stratégies d'injection de poids (w_c) dans la fonction de coût.

Dans un premier temps, nous avons testé l'approche standard dite « Balanced », qui consiste à attribuer à chaque classe un poids inversement proportionnel à sa fréquence d'apparition. Cependant, nos tests préliminaires, menés notamment sur le Random Forest, ont mis en évidence les limites de cette contrainte. En imposant au modèle d'accorder une importance artificielle équivalente au match nul et à la victoire, cette méthode a engendré une augmentation massive du taux de Faux Positifs. Le modèle, cherchant à minimiser sa perte globale, a eu tendance à dégrader l'Accuracy globale en le passant en dessous du seuil critique de 49 %.

Face à ce constat d'échec, notre choix s'est porté sur une stratégie unifiée reposant sur une pénalisation asymétrique modérée. Plutôt qu'un rééquilibrage mathématique strict, nous avons défini un vecteur de poids manuel attribuant une sur-pondération marginale de 10 % à la classe du match nul ($w_{\{D\}} = 1.1$), tout en maintenant un poids standard pour les victoires ($w_{\{H\}} = w_{\{A\}} = 1.0$). Cette approche permet d'inciter le modèle à considérer davantage l'incertitude du nul sans pour autant déstabiliser la structure globale des prédictions.

6.3.2 Le Ratio Signal/Bruit

Mathématiquement, cela signifie qu'une erreur de prédiction sur un match nul coûte 10% plus cher en termes de Log Loss qu'une erreur sur une victoire.

Cette stratégie repose sur un constat fondamental : le ratio signal/bruit de la classe Nul est faible.

Les résultats empiriques (détaillés en dans la partie suivante) valident cette approche. Face à un signal bruité, les modèles convergent vers une optimisation d'évitement du risque : ils privilégient les classes majoritaires (Victoires) où les prédictors (Elo, Cotes) sont importants.

Nous assumons ce parti-pris : pour maximiser la rentabilité et la précision globale, il est préférable d'accepter un faible rappel sur les nuls plutôt que de polluer les prédictions avec des nuls inexistants.

7. Modélisation Prédictive et Analyse Comparative

Nous avons choisi de comparer trois familles d'algorithmes distinctes. Sauf la Régression Logistique servant de référence (baseline), nous nous sommes orientés vers des méthodes ensemblistes (Random Forest, XGBoost). Ce choix est motivé par les travaux de Baboota & Kaur [4], qui ont démontré sur la Premier League que ces architectures de Machine Learning surclassent systématiquement les modèles statistiques traditionnels en capturant mieux les non-linéarités du jeu.

7.1 Baseline : La Régression Logistique (RL)

7.1.1 Présentation de la Méthode

Le choix de la Régression Logistique comme point de départ répond au principe de parcimonie. Il s'agit d'un modèle linéaire généralisé qui estime la probabilité d'appartenance à une classe (Home, Draw, Away) en appliquant une fonction d'activation (Softmax) à une combinaison linéaire des variables explicatives.

Chaque variable se voit attribuer un poids (β_i) lisible, permettant de quantifier l'influence des facteurs (ex: Elo vs Tirs). De plus, la fonction de coût est convexe, garantissant l'optimum global. Enfin, elle permet de vérifier si le phénomène est linéairement séparable. Si la RL performe bien, l'usage de boîtes noires devient superflu.

7.1.2 Validation du Benchmark : Le Test de Contrôle (V1)

Avant d'évaluer la puissance pure des statistiques avec le modèle dit « Aveugle », nous avons réalisé un test de contrôle en incluant les cotes des bookmakers comme variables d'entrée. L'objectif était de vérifier la capacité de l'algorithme à reproduire le consensus du marché.

Voici les résultats qu'on obtient :

- Accuracy RL (avec cotes) : 53.39%.
- Accuracy Marché (V0) : 53.63%.
- Delta : -0.24%.

Ce résultat démontre que l'algorithme est techniquement capable d'égaler le marché s'il dispose de la même information. La baisse de performance observée par la suite proviendra donc d'une asymétrie d'information, et non d'une limite du modèle linéaire.

7.1.3 Performance du Modèle Aveugle (V2)

Le modèle final, privé des cotes et n'utilisant que les 36 variables endogènes (Elo + Stats Techniques), affiche les performances suivantes sur le jeu de test :

- Accuracy : 52.45% (vs 53.63% pour le Marché).
- Différentiel : -1.18 points.

- Log Loss : 0.9843.

Le modèle parvient à capter près de 98% du signal prédictif du marché uniquement grâce à l'historique technique.




Figure 5 : Importance des variables dans la Régression Logistique

L'analyse des coefficients standardisés (Figure 5) explique cette performance : les variables structurelles (EloAdvantage, EloDiff) dominent les indicateurs micro-techniques. Le poids du Elo est environ 7 fois supérieur à celui de la forme récente (Shots_Last5).

7.1.4 Analyse Comportementale : Le Biais de la Classe Majoritaire

Si l'Accuracy est élevée, l'analyse fine de la Matrice de Confusion révèle une rigidité structurelle majeure.




Figure 6 : Matrice de confusion de la Régression Logistique

Comme l'illustrent les métriques de rappel de la Figure 6 :

- Recall Home (Victoire Domicile) : 84.2%.
- Recall Away (Victoire Extérieur) : 48.0%.
- Recall Draw (Match Nul) : 1.4%.

La Régression Logistique cherche à séparer les classes par des hyperplans droits. Or, la classe "Match Nul" ne se situe pas aux extrêmes, mais dans une zone tampon. Incapable d'isoler cette topologie, le modèle sacrifie mathématiquement le match nul pour maximiser son Accuracy globale sur les classes majoritaires. C'est un classifieur efficace pour dégager une tendance, mais manquant de nuance pour l'incertitude.

7.2 Challenger : Random Forest (RF)

7.2.1 Présentation de la Méthode : Réduction de la Variance

Pour tenter de dépasser les limitations structurelles de la linéarité, nous avons sollicité la famille des algorithmes d'ensemble. Le Random Forest repose sur la technique du Bagging : il construit une multitude d'arbres de décision décorrélés entraînés sur des sous-échantillons aléatoires. Cette architecture vise théoriquement à réduire la variance et à capturer les

interactions non-linéaires complexes (ex: une équipe forte à domicile mais faible face à un bloc défensif bas), là où la régression logistique ne voit qu'une addition de forces.

7.2.2 Validation du Benchmark (V1)

Le test de contrôle (avec cotes) confirme la capacité d'apprentissage du modèle :

- Accuracy RF (avec cotes) : 53.41%.
- Accuracy Marché : 53.63%.
- Delta : -0.22%.




Figure 7 : Importance des variables (Random Forest)

L'analyse d'importance des variables (Figure 7) montre que le modèle hybride bien l'information : si les cotes dominent (OddHome), les variables Elo reste très influentes (EloDiff), signe que l'arbre parvient à hiérarchiser les signaux.

7.2.3 Performance du Modèle Aveugle (V2)

Une fois privé des cotes, le Random Forest affiche une performance quasi-identique à la baseline linéaire, échouant à extraire un signal supplémentaire caché.

- Accuracy : 52.47% (vs 52.45% pour la RL).
- Log Loss : 0.9871 (vs 0.9843 pour la RL).

C'est un résultat contre-intuitif. Le gain de complexité algorithmique ne se traduit par aucun gain de performance. Pire, la dégradation de la Log Loss indique que le modèle est moins bien calibré : ses probabilités sont moins fiables que celles du modèle linéaire. Cela suggère que la frontière de décision du football est majoritairement linéaire et que les arbres sur-interprètent le bruit statistique.

7.2.4 Analyse Comportementale

Le résultat le plus frappant réside dans le comportement stratégique adopté par l'algorithme face à l'incertitude.




Figure 8 : Matrice de confusion du modèle Random Forest

Comme le montre la Figure 8, le Random Forest accentue le biais observé sur la RL :

- Recall Home (Victoire Domicile) : 85.7%.
- Recall Draw (Match Nul) : 1.1%.
- Recall Away (Victoire Extérieur) : 45.9%.

Confronté à l'entropie élevée des matchs nuls, l'algorithme parie massivement sur la classe majoritaire. Il converge vers une solution d'optimisation locale prudente : avoir raison souvent sur les matchs faciles, et ignorer les matchs complexes. C'est efficace pour l'Accuracy, mais mauvais pour la recherche de Value.

7.3 Le Gradient Boosting (XGBoost)

7.3.1 Présentation de la Méthode : Correction Séquentielle

Pour finaliser notre exploration, nous avons déployé le XGBoost (Extreme Gradient Boosting), le meilleur modèle pour les données tabulaires structurées. Contrairement au Random Forest

qui construit des arbres indépendants en parallèle pour réduire la variance, le Boosting adopte une approche séquentielle. Chaque nouvel arbre de décision est entraîné spécifiquement pour prédire et corriger les erreurs résiduelles de l'ensemble des arbres précédents. Cette mécanique itérative permet une gestion beaucoup plus fine du compromis Biais/Variance : le modèle apprend activement des cas difficiles que les modèles linéaires peinent à classer.

7.3.2 Paramétrage et Stratégie de Régularisation

La stratégie de paramétrage du modèle XGBoost a été dictée par la nature stochastique du phénomène modélisé. Loin de la recherche d'une optimisation marginale des hyperparamètres via un GridSearch qui est une méthode souvent synonyme de sur-ajustement sur des données aussi bruitées que celles du sport, nous avons privilégié une approche conservatrice axée sur la capacité de généralisation. Cette volonté s'est traduite par trois choix précis.

En premier lieu, nous avons imposé une contrainte forte de complexité en limitant la profondeur des arbres à 4 niveaux (`max_depth=4`). Cette restriction force l'algorithme à se concentrer sur les interactions structurelles dominantes et logiques (telles que la combinaison entre un écart de Elo élevé et l'avantage du terrain), l'empêchant mécaniquement de mémoriser des scénarios anecdotiques ou des micro-motifs non reproductibles.

Parallèlement, nous avons introduit de la diversité via le mécanisme de sous-échantillonnage (`subsample=0.8`). Inspirée de la méthode du Random Forest, cette technique consiste à n'utiliser que 80 % des données et des variables pour la construction de chaque arbre. Ce procédé agit comme un garde-fou et prévient toute dépendance du modèle envers une variable spécifique ou une observation aberrante.

Enfin, la dynamique d'optimisation a été contrôlée par un processus de convergence graduelle. En couplant un taux d'apprentissage faible (`learning_rate=0.05`) à un nombre d'estimateurs fixe (300 arbres), nous obligeons le modèle à converger lentement. Cette approche réduit la variance de la prédiction finale comparativement à un apprentissage rapide, garantissant une meilleure stabilité des performances sur les données de test futures.

7.3.3 Validation du Benchmark : Le Test de Contrôle (V1)

Le test de contrôle, réalisé en incluant les cotes des bookmakers comme features, confirme la capacité d'apprentissage de l'algorithme :

- Accuracy XGB (avec cotes) : 52.54%.
- Accuracy Marché : 53.63%.
- Delta : -1.09%.

Bien que l'écart soit légèrement plus marqué que pour les modèles précédents, le modèle parvient à reproduire fidèlement le consensus du marché.

7.3.4 Performance du Modèle Aveugle (V2)

Sur le jeu de test final (sans cotes), le modèle affiche les résultats suivants :

- Accuracy : 51.86% (Inférieure au RF à 52.47%).
- Log Loss : 0.9929 (Supérieure au RF à 0.9871).

En apparence, le XGBoost régresse par rapport au Random Forest. Pourtant, cette lecture est trompeuse. Là où le Random Forest maximisait artificiellement son Accuracy en sur-prédisant les favoris, le XGBoost tente une modélisation plus fidèle de la distribution réelle. Il accepte de perdre en précision globale pour gagner en granularité structurelle.

7.3.5 Analyse Structurale

C'est dans la matrice de confusion que le XGBoost justifie son statut de modèle le plus abouti.




Figure 9 : Matrice de confusion du XGBoost

Comme le montre la Figure 9, le modèle propose une distribution de probabilités plus nuancée :

- Recall Home (Victoire Domicile) : 81.5% (Moins agressif que le RF à 86%).
- Recall Draw (Match Nul) : 6.0% (Nettement supérieur au RF à 1%).
- Recall Away (Victoire Extérieur) : 46.1%.

Alors que le Random Forest avait abandonné les matchs nuls, le XGBoost parvient à capter un signal faible sur cette classe. Il refuse la solution de facilité (tout miser sur le Domicile) et tente de capturer l'incertitude réelle du sport.

7.3.6 Calibration et Fiabilité (ECE)

Au-delà du classement, la qualité fondamentale pour une application de paris est la calibration.




Figure 10 : Courbe de calibration du XGBoost

D'après la Figure 10, on observe qu'avec une Expected Calibration Error (ECE) de 1.7%, le XGBoost est un modèle très bien calibré.

Cela signifie que le modèle est honnête. Lorsqu'il annonce une probabilité de victoire de 60%, l'événement se produit réellement dans 60% des cas. C'est la condition pour calculer une espérance de gain mathématique dans la partie suivante.

7.3.7 Décryptage de la Boîte Noire

L'analyse de la structure interne du modèle (via l'Arbre 0 et les valeurs SHAP) confirme la hiérarchie de l'information apprise.

La toute première décision prise par l'algorithme (le nœud racine) se base systématiquement sur EloDiff, avec un gain d'information massif. Les variables techniques comme HomeShots n'interviennent qu'aux niveaux inférieurs.




Figure 11 : Importance globale des variables du XGBoost (SHAP Values)

La Figure 11 valide notre hypothèse : le modèle fonctionne selon une logique pseudo-bayésienne. Le Elo fournit la tendance lourde et les statistiques récentes permettent d'ajuster le posterior à la marge.

7.3.8 Diagnostic Limite : L'Asymptote d'Information




Figure 12 : Courbes d'apprentissage du XGBoost

Enfin, l'analyse des courbes d'apprentissage (Figure 12) montre une convergence rapide des scores d'entraînement et de validation vers un plateau asymptotique. L'ajout de données supplémentaires ne réduit plus l'erreur : nous avons atteint l'Erreur de Bayes accessible avec ces variables. Le plafond de verre de 52% d'Accuracy n'est pas dû à une faiblesse du XGBoost, mais à l'absence de variables explicatives cruciales (blessures, météo, contextes humains) que l'historique statistique ne contient pas.

8. Discussion Critique et Analyse Financière

Au-delà des métriques algorithmiques abstraites (Log Loss, Accuracy), la validation ultime d'un modèle prédictif dans le domaine sportif réside dans sa capacité à se confronter à la réalité économique du marché.

Si la 4^{ème} Partie a désigné le XGBoost comme notre architecture de référence pour sa qualité de calibration, cette dernière partie vise à répondre à la problématique centrale du projet sous l'angle de l'efficacité : l'information endogène suffit-elle pour générer un profit face aux bookmakers ?

8.1 Cadre d'Analyse et Rentabilité Comparée

Avant de présenter les résultats empiriques, il est nécessaire de définir les concepts économiques qui servent à notre évaluation. Contrairement à une classification classique où l'on cherche simplement à avoir raison, ici nous cherchons à avoir plus raison que le marché.

8.1.1 Définitions des Métriques Financières

Afin de garantir une crédibilité aux résultats et leur comparabilité avec les standards de l'industrie, nous avons ancré notre évaluation économique sur trois concepts fondamentaux.

Au cœur de notre stratégie réside la notion de « Value » (Espérance de Gain). Contrairement à une approche probabiliste pure, nous ne déclenchons une prise de position que lorsque notre probabilité estimée (P_{model}) est strictement supérieure à la probabilité implicite définie par la cote du bookmaker ($P_{\text{impl}} = 1 / \text{Cote}$). Ce différentiel matérialise l'avantage théorique du modèle sur le consensus du marché. Cependant, pour être rentable, cet avantage doit être suffisant pour compenser la Marge du Bookmaker. Cette commission, matérialisée par une somme des probabilités implicites supérieure à 100 % (généralement entre 105 % et 106 %), impose un handicap structurel d'environ -5,5 % que tout modèle doit surmonter avant de générer le premier euro de profit net.

Enfin, pour isoler la performance intrinsèque du modèle de toute variance liée à la gestion de portefeuille, nous avons adopté un protocole de mise unitaire. Chaque pari engage une mise fixe d'une unité (1u), neutralisant ainsi les biais qu'auraient pu introduire des stratégies de gestion de mise progressives ou agressives.

8.1.2 Analyse de Rentabilité (ROI) des 3 Modèles

Nous avons simulé une campagne de paris sur l'ensemble du jeu de test, en pariant 1 unité chaque fois que le modèle détectait de la valeur ($\text{Value} > 0$).




Figure 13 : Évolution du profit cumulé (en unités)

Les résultats financiers, synthétisés sur la Figure 13, permettent de hiérarchiser les modèles :

- Régression Logistique (RL) : ROI -7.05%

Le modèle souffre de sa moins bonne calibration. Il surestime souvent ses chances sur les favoris, nous faisant parier sur des cotes sans valeur réelle.

- Random Forest (RF) : ROI -6.29%

Bien qu'ayant la meilleure Accuracy brute, le RF est moins performant financièrement que le XGBoost.

- XGBoost : ROI -5.79%

Grâce à son excellente calibration (ECE faible), le XGBoost limite la casse. C'est le modèle qui perd le moins d'argent, s'alignant presque parfaitement sur la probabilité réelle moins la marge du bookmaker.

8.1.3 La Neutralité face à l'Efficiency (EMH)

Le fait qu'aucun modèle ne génère de profit net (ROI positif) ne doit pas être interprété comme un échec technique, mais comme une validation de l'Hypothèse d'Efficiency des Marchés (EMH).

Le ROI du XGBoost (-5.79%) est statistiquement indiscernable de la marge moyenne prélevée par les bookmakers sur les championnats retenus (~5.5%). Ce résultat constitue une validation de l'Hypothèse d'Efficiency des Marchés (EMH), et rejoint les conclusions d'Angelini & De Angelis [5]. Ces auteurs ont démontré que sur les grands championnats européens, les cotes

intègrent l'information publique avec une telle véracité que les opportunités d'arbitrage systématique sont statistiquement nulles.

Si notre modèle était aléatoire, le ROI serait catastrophique ($< -15\%$). Le fait qu'il s'aligne sur la marge prouve qu'il est neutre. Il reproduit la connaissance du marché avec la même précision que le bookmaker, mais sans l'Alpha nécessaire pour compenser la taxe d'entrée.

Ce résultat met en lumière le plafond de verre de l'information endogène : le marché a déjà intégré dans les prix toute l'information contenue dans nos variables historiques (Elo, Forme).

8.2 Profilage de la Performance et Zones de "Value"

L'analyse d'un ROI global moyen peut masquer des disparités locales. Nous avons segmenté les résultats par tranches de cotes pour identifier les forces et faiblesses structurelles.

8.2.1 La Dichotomie Favori / Outsider




Figure 14 : Rentabilité par tranche de cote

L'analyse de la Figure 14 met en lumière deux régimes distincts :

Tout d'abord, la zone de résilience (Cotes < 1.50). Sur le segment des matchs très déséquilibrés (David vs Goliath), nos modèles sont robustes. Le XGBoost parvient presque à l'équilibre (ROI -1.15%), neutralisant efficacement la marge. La Régression Logistique crée la surprise avec un ROI positif de $+3.64\%$ (sur 166 paris).

Lorsque la hiérarchie est claire, la linéarité du modèle logistique est un atout. Il identifie les paris sans risque sans introduire le bruit que les modèles complexes peuvent parfois capter.

Enfin, la zone de danger (Cotes > 3.00). Dès que l'on entre dans la zone d'incertitude (Gros Outsiders), la performance s'effondre. Le ROI du XGBoost plonge à -8.95%.

Nos modèles souffrent ici d'un déficit d'information critique. Pour qu'un outsider gagne, il faut souvent un événement exogène (blessure, contexte psychologique) que nos statistiques ne contiennent pas. Le modèle surestime la probabilité de l'exploit mathématique.

8.2.2 Mise en Garde Épistémologique

Il est impératif de traiter le ROI positif de la RL sur les favoris (+3.64%) avec prudence. Isoler a posteriori un sous-segment gagnant pour prétendre avoir trouvé une stratégie rentable relèverait du biais de sélection.

Nous concluons à une meilleure efficacité relative sur les favoris, ce résultat pouvant être influencé par la variance sur un faible échantillon (166 paris).

8.3 Analyse Comparative face au Consensus de Marché

Pour évaluer la pertinence réelle de nos modèles, nous les comparons au standard : le Consensus du Marché.

8.3.1 Définition du Benchmark (V0) et Performance Relative

Nous comparons ici notre stratégie de référence (suivre le favori du marché) à notre meilleur modèle global, le XGBoost Aveugle (V2).

- Accuracy du Marché (V0 avec information "Totale") : 53.63 %
- Accuracy du Modèle XGB (V2 avec information "Historique") : 51.86 %
- Différentiel de Performance : -1.77 points

Ce différentiel est très faible. Bien que le marché reste supérieur (attendu compte tenu de l'asymétrie d'information), notre modèle historique n'est pas très loin. Si Hubáček et al. [3] rapportent des résultats similaires (52-53%) confirmant que nous avons atteint le plafond des données historiques, ce constat illustre également la quête du Saint Graal décrite par Tax & Joustra [6] : sans information privilégiée (exogène), le Machine Learning sature à une asymptote de précision qui frôle celle des bookmakers sans jamais réussir à la dépasser suffisamment pour être rentable.

8.3.2 La Règle du 95/5

Ce différentiel nous permet de proposer une décomposition quantitative de la valeur de l'information dans le football professionnel. Si l'on considère le marché comme l'asymptote de la prédiction parfaite, notre modèle parvient à capturer 96.7% de cette performance (51.86 / 53.63).

Cela nous conduit à formuler les hypothèses suivantes sur la structure du signal :

A propos de l'information structurelle (~95% du signal utile). Les données endogènes (Elo, Historique) capturent l'immense majorité de la variance explicable. Une machine qui ne connaît que le passé (notre modèle) converge vers la même conclusion que l'expert qui connaît le présent (le bookmaker) dans la quasi-totalité des cas.

A propos de l'alpha exogène (~5% du signal résiduel). L'écart résiduel de ~1.8% représente la valeur ajoutée des informations privées ou temps réel (compositions, blessures) que possède le bookmaker mais pas notre modèle.

9. Discussion : Limites et Obstacles Rencontrés

Ce projet a mis en lumière que la difficulté majeure de la Data Science appliquée ne réside pas tant dans la modélisation algorithmique que dans la constitution d'une base de données fiable. Sur le plan de l'ingénierie, la fusion des sources hétérogènes a été critique : comme détaillé en Partie 4, l'absence de clé primaire commune a nécessité une stratégie de réconciliation complexe avec le Fuzzy Matching. Sans cette étape, le rejet de près de 40 % des observations aurait introduit un biais conséquent, faussant l'apprentissage sur les outsiders.

Par ailleurs, la gestion de la classe minoritaire « Match Nul » a constitué notre principale limite. La tendance naturelle des algorithmes à sacrifier cette classe pour maximiser l'Accuracy globale nous a contraints à adopter un compromis. Plutôt que de forcer la détection par des pondérations agressives, nous avons validé qu'une stratégie de pénalisation douce offrait le meilleur équilibre.

10. Conclusion Générale et Perspectives

Au terme de cette étude, qui a mobilisé l'analyse de plus de 52580 matchs professionnels sur deux décennies, nous sommes en mesure d'apporter une réponse à notre problématique initiale : l'information statistique publique suffit-elle pour battre les bookmakers ?

La confrontation de nos trois architectures a permis d'établir une hiérarchie de performance claire :

Le XGBoost s'impose comme la référence. En optimisant le compromis biais-variance, il offre la meilleure calibration ($ECE < 1.7 \%$), prouvant qu'il extrait le nécessaire du signal historique disponible.

La Régression Logistique a joué son rôle de *baseline* en démontrant que la structure fondamentale de la prédiction reste linéaire (dominée par le Elo), bien qu'elle pêche par excès de confiance aux extrêmes.

Le Random Forest, enfin, a montré ses limites sur ce type de données déséquilibrées, sa stratégie de maximisation de l'Accuracy se traduisant par une performance moins bonne.

D'un point de vue technique, le projet est réussi : nous sommes parvenus à reconstruire la probabilité du marché avec une fidélité supérieure à 97 %. Cependant, le ROI négatif du meilleur modèle (-5.79 %) confirme l'Hypothèse d'Efficiency des Marchés (EMH) discutée précédemment. Les données endogènes (scores, Elo) permettent d'atteindre la neutralité, c'est-à-dire de ne pas perdre plus que la marge du bookmaker mais saturent face à un plafond de verre. Parier sur ces seules variables revient à parier sur un consensus que le marché a déjà parfaitement intégré.

Pour franchir ce mur de l'efficience, et comme le suggèrent Kaunitz et al. [7], l'optimisation des hyperparamètres ne suffira plus : il faut changer de paradigme. La suite réside dans l'enrichissement de l'information :

On pourrait intégrer les compositions d'équipes et les blessures en temps réel, ce qui serait le levier manquant pour capter la variance non-statistique.

On pourrait également remplacer les tirs bruts par des Expected Goals (xG), permettant de réduire le bruit en qualifiant la dangerosité réelle des actions.

Enfin, on pourrait développer des modèles intra-match pour exploiter les inefficiences de réaction du marché en temps réel, là où l'humain est sujet aux biais émotionnels.

11. Apport Personnel et Retour d'Expérience

Ce projet de fin d'études a constitué pour nous une immersion dans la réalité du métier de Data Scientist.

Nous avons consolidé notre maîtrise de la chaîne de valeur de la donnée.

L'apport le plus significatif reste sans doute l'apprentissage de l'humilité scientifique. Accepter, analyser et expliquer un ROI négatif nous a permis de comprendre que la valeur d'une étude réside dans la pertinence de son protocole, pas uniquement dans le signe de son résultat final.

Enfin, ce projet a définitivement mis en lumière la prédiction sportive. Nous avons compris qu'il ne s'agit pas d'un jeu de hasard, mais d'un problème d'information. Nous avons construit une machine capable d'égaler l'expert, mais nous avons aussi compris pourquoi sans informations privilégiées, l'avantage structurel du teneur de marché reste mathématiquement insurmontable.

12. Bibliographie

- [1] Hvattum, L. M., & Arntzen, H. (2010). *Using ELO ratings for match result prediction in association football*. International Journal of Forecasting, 26(3), 460-470.
- [2] Dixon, M. J., & Coles, S. G. (1997). *Modelling association football scores and inefficiencies in the football betting market*. Applied Statistics, 265-280.
- [3] Hubáček, O., Šourek, G., & Železný, F. (2019). *Learning to predict soccer results from relational data with gradient boosted trees*. Machine Learning and Knowledge Discovery in Databases.
- [4] Baboota, R., & Kaur, H. (2019). *Predictive analysis and modelling football results using machine learning approach for English Premier League*. International Journal of Forecasting, 35(2), 741-755.
- [5] Angelini, G., & De Angelis, L. (2019). *Efficiency of online football betting markets*. International Journal of Forecasting, 35(2), 712-721.
- [6] Tax, N., & Joulstra, Y. (2015). *Looking for the Holy Grail: A machine learning approach to winning at sports betting*.
- [7] Kaunitz, L., et al. (2017). *Beating the bookies with their own numbers - and how the online sports betting market is rigged*.

13. Annexe

13.1 Dictionnaire des Variables

Nom de la Variable (Feature)	Type	Description / Formule
EloDiff	Numérique	Différence de niveau : $Elo_{\{Home\}} - Elo_{\{Away\}}$
EloAdvantage	Binaire	1 si $EloDiff > 0$ (l'équipe à domicile est favorite), sinon 0.
Form5Diff	Numérique	Différence de points pris sur les 5 derniers matches.
Form3Diff	Numérique	Différence de forme à très court terme (3 derniers matches).
FormMomentumHome	Numérique	Dynamique de forme Domicile : $Forme_{\{3m\}} - Forme_{\{5m\}}$
FormMomentumAway	Numérique	Dynamique de forme Extérieur (Même logique).
H_HomeShots_Last5	Numérique	Moyenne des tirs tentés par l'équipe Domicile lors de ses 5 derniers matches à domicile.
A_AwayShots_Last5	Numérique	Moyenne des tirs tentés par l'équipe Visiteur lors de ses 5 derniers matches à l'extérieur.
H_HomeTarget_Last5	Numérique	Moyenne des tirs cadrés (<i>On Target</i>) de l'équipe Domicile (Précision).
A_AwayTarget_Last5	Numérique	Moyenne des tirs cadrés de l'équipe Visiteur.
H_FTHomeGoals_Last5	Numérique	Moyenne des buts marqués par l'équipe Domicile (Attaque).
A_FTAwayGoals_Last5	Numérique	Moyenne des buts marqués par l'équipe Visiteur (Attaque).
H_HomeCorners_Last5	Numérique	Moyenne des corners obtenus par l'équipe Domicile (Pression territoriale).
A_AwayCorners_Last5	Numérique	Moyenne des corners obtenus par l'équipe Visiteur.
H_GameDominanceIndex_Last5	Numérique	Indicateur composite Domicile : $(Tirs + Corners)/2$
A_GameDominanceIndex_Last5	Numérique	Indicateur composite Extérieur.
H_ShotsDifference_Last5	Numérique	Différentiel moyen de tirs (Tirs Pour - Tirs Contre) de l'équipe Domicile.
A_ShotsDifference_Last5	Numérique	Différentiel moyen de tirs de l'équipe Visiteur.
H_FTAwayGoals_Last5	Numérique	Moyenne des buts <i>encaissés</i> par l'équipe Domicile (Friabilité défensive).

A_FTHomeGoals_Last5	Numérique	Moyenne des buts <i>encaissés</i> par l'équipe Visiteuse.
H_HomeFouls_Last5	Numérique	Moyenne des fautes commises par l'équipe Domicile (Agressivité).
A_AwayFouls_Last5	Numérique	Moyenne des fautes commises par l'équipe Visiteuse.
H_HomeYellow_Last5	Numérique	Moyenne des cartons jaunes reçus par l'équipe Domicile.
A_AwayYellow_Last5	Numérique	Moyenne des cartons jaunes reçus par l'équipe Visiteuse.
H_CardsDiff_Last5	Numérique	Différentiel disciplinaire Domicile (Cartons Reçus - Cartons Provoqués).
A_CardsDiff_Last5	Numérique	Différentiel disciplinaire Extérieur.
H_CornersDifference_Last5	Numérique	Différentiel de corners (Obtenus - Concédés) pour l'équipe Domicile.
A_CornersDifference_Last5	Numérique	Différentiel de corners pour l'équipe Visiteuse.
H_HomeRed_Last5	Numérique	Moyenne des cartons rouges (Indicateur de perte de contrôle).
A_AwayRed_Last5	Numérique	Moyenne des cartons rouges pour l'équipe Visiteuse.

13.2 Paramètres des Modèles (Reproductibilité)

Régression Logistique :

- Solver : lbfgs
- Max Iter : 1000
- Class Weight : {'0':1, '1':1.1, '2':1}

Random Forest :

- N Estimators : 100
- Max Depth : None
- Criterion : Gini

XGBoost :

- Objective : multi:softprob
- N Estimators : 300
- Learning Rate : 0.05
- Max Depth : 4
- Subsample : 0.8
- Colsample_bytree : 0.8

13.3 Exemple de Réconciliation (Fuzzy Matching)


	A	B	C	D	E
1	club_missing	suggested_ma	similarity	countries_considered	
2	Akron Togliatti	Akron Togliatti	100.0	RUS	
3	BW Linz	BW Linz	100.0	AUT	
4	Baltika	Baltika	100.0	RUS	
5	Falkirk	Falkirk	100.0	SCO	
6	Dynamo Makh	Dynamo Makh	100.0	RUS	
7	Colchester	Colchester	100.0	ENG	
8	Corona Braso	Corona Braso	100.0	ROM	
9	Doncaster	Doncaster	100.0	ENG	
10	Cardiff	Cardiff	100.0	ENG	
11	Chindia Targov	Chindia Targov	100.0	ROM	
12	Bristol City	Bristol City	100.0	ENG	
13	Burton	Burton	100.0	ENG	
14	Brighton	Brighton	100.0	ENG	
15	Brentford	Brentford	100.0	ENG	
16	Bournemouth	Bournemouth	100.0	ENG	
17	Blackpool	Blackpool	100.0	ENG	
18	Queen of St	Queen of St	100.0	SCO	
19	Rakow	Rakow	100.0	POL	
20	Reading	Reading	100.0	ENG	
21	Ranheim	Ranheim	100.0	NOR	

13.4 Tableaux de Résultats Financiers (extrait notebook modélisation XGBoost)



ANALYSE DE RENTABILITÉ (MODELE AVEUGLE)				
Simulation des paris (Mise fixe = 1 unité) :				
Seuil Value >	Nb Paris	ROI	Profit	Total
0%	24821	-5.79%	-1436.6u	
5%	20700	-6.48%	-1341.1u	
10%	16063	-7.35%	-1180.9u	
15%	12109	-8.20%	-992.8u	
20%	9030	-8.69%	-784.4u	

13.5 La Visualisation de l'Arbre XGBoost (Tree Plot)

Visualisation pédagogique : Les 3 premiers niveaux d'un arbre



13.6 Visualisation SHAP importance pour respectivement RL et RF avec l'influence (cas du modèle aveugle)



13.7 Courbe d'apprentissage pour RL

